Albert Ludwigs Universität Freiburg

TECHNISCHE FAKULTÄT

PicoC-Compiler

Übersetzung einer Untermenge von C in den Befehlssatz der RETI-CPU

BACHELORARBEIT

 $Abgabedatum: 28^{th}$ April 2022

Author: Jürgen Mattheis

Gutachter:
Prof. Dr. Scholl

Betreung: M.Sc. Seufert

Eine Bachelorarbeit am Lehrstuhl für Betriebssysteme

ERKLÄRUNG
ERRLARUNG
Hiermit erkläre ich, dass ich diese Abschlussarbeit selbständig verfasst habe, keine anderen
als die angegebenen Quellen/Hilfsmittel verwendet habe und alle Stellen, die wörtlich oder
sinngemäß aus veröffentlichten Schriften entnommen wurden, als solche kenntlich gemacht
habe. Darüber hinaus erkläre ich, dass diese Abschlussarbeit nicht, auch nicht
auszugsweise, bereits für eine andere Prüfung angefertigt wurde.

Inhaltsverzeichnis

1	Mot	lotivation	7
	1.1	1 PicoC und RETI	7
	1.2	2 Aufgabenstellung	7
	1.3	3 Eigenheiten der Sprache C	7
	1.4		
${f 2}$	Einf	inführung	8
_	2.1		
	2.1	2.1.1 T-Diagramme	
	2.2		
	2.3		
	2.3	3 Grundlagen	
	0.4		
	2.4		
	2.5		
	2.6		
	2.7	Fehlermeldungen	14
3	Imp	nplementierung	15
	3.1	1 Lexikalische Analyse	15
		3.1.1 Verwendung von Lark	15
		3.1.2 Basic Parser	15
	3.2	2 Syntaktische Analyse	15
		3.2.1 Verwendung von Lark	15
		3.2.2 Umsetzung von Präzidenz	
		3.2.3 Derivation Tree Generierung	
		3.2.4 Early Parser	
		3.2.5 Derivation Tree Vereinfachung	
		3.2.6 Abstrakt Syntax Tree Generierung	
	3.3		
	0.0	3.3.1 Passes	
		3.3.2 Umsetzung von Pointern und Arrays	
		3.3.3 Umsetzung von Structs	
		3.3.4 Umsetzung von Funktionen	
		3.3.5 Umsetzung kleinerer Details	
	3.4		
	3.4		
		3.4.1 Error Handler	16
4	Erg	rgebnisse und Ausblick	17
	4.1		
	4.2	•	
	4.3	3 Kommentierter Kompiliervorgang	17
	4.4	4 Erweiterungsideen	17
A	Apr	ppendix	18
-		1 Konkrette und Abstrakte Syntax	
		2 Bedienungsanleitungen	

Inhaltsverzeichnis Inhaltsverzeichnis

A.2.2 Showmode	ſ	A.2.1	PicoC-Compiler
		A.2.2	Showmode
		A.2.3	

Abbildungsverzeichnis	

Tabellenverzeichnis

Definitionen

1	Compiler
2	Interpreter
3	T-Diagram
4	Sprache
5	Chromsky Hierarchie
6	Grammatik
7	Reguläre Sprachen
8	Kontextfreie Sprachen
9	Ableitungsbaum
10	Mehrdeutige Grammatik
11	Assoziativität
12	Präzidenz
13	Pattern
14	Lexeme 9
15	Lexer (bzw. Scanner)
16	Literal
17	Konkrette Syntax
18	Derivation Tree (bzw. Parse Tree)
19	Parser
20	Recognizer (bzw. Erkenner)
21	Transformer
22	Visitor
23	Abstrakte Syntax
24	Abstrakte Syntax Tree
25	Pass
26	Fehlermeldung
27	Symboltabelle

1 Motivation

- 1.1 PicoC und RETI
- 1.2 Aufgabenstellung
- 1.3 Eigenheiten der Sprache C
- 1.4 Richtlinien

2 Einführung

2.1 Compiler und Interpreter		
Def	inition 1: Compiler	
Def	inition 2: Interpreter	
2.1.1	T-Diagramme	
Def	inition 3: T-Diagram	
2.2	Grammatiken	
2.3	Grundlagen	
Def	inition 4: Sprache	
Def	inition 5: Chromsky Hierarchie	
Def	inition 6: Grammatik	
DCI.	intion of Granmatik	
Dof	inition 7: Reguläre Sprachen	
Del	midon 7. Regulare Sprachen	

Definition 8: Kontextfreie Sprachen

2.3.1 Mehrdeutige Grammatiken

Definition 9: Ableitungsbaum

Definition 10: Mehrdeutige Grammatik

2.3.2 Präzidenz und Assoziativität

Definition 11: Assoziativität

Definition 12: Präzidenz

2.4 Lexikalische Analyse

Die Lexikalische Analyse bildet üblicherweise die erste Ebene innerhalb der Pipe Architektur bei der Implementierung von Compilern. Die Aufgabe der lexikalischen Analyse ist vereinfacht gesagt, in einem Inputstring, z.B. dem Inhalt einer Datei, welche in UTF-8 codiert ist, Folgen endlicher Symbole (auch Wörter genannt) zu finden, die bestimmte Pattern (Definition 13) matchen, die durch eine reguläre Grammatik spezifiziert sind.

Definition 13: Pattern

Beschreibung aller möglichen Lexeme einer Menge \mathbb{P}_T , die einem bestimmten Token T zugeordnet werden. Die Menge \mathbb{P}_T ist eine möglicherweise unendliche Menge von Wörtern, die sich mit den Produktionen einer regulären Grammatik G_{Lex} einer regulären Sprache L_{Lex} beschreiben lassen a, die für die Beschreibung eines Tokens T zuständig sind.

Diese Folgen endlicher Symoble werden auch Lexeme (Definition 14) genannt.

Definition 14: Lexeme

Ein Lexeme ist ein Wort aus dem Inputstring, welches das Pattern für eines der Token T einer Sprache L_{Lex} matched.^a

 $[^]a$ Als Beschreibungswerkzeug können aber auch z.B. reguläre Ausdrücke hergenommen werden.

^bWhat is the difference between a token and a lexeme?

^aWhat is the difference between a token and a lexeme?

Diese Lexeme werden vom Lexer im Inputstring identifziert und Tokens T zugeordnet (Definition 15). Die Tokens sind es, die letztendlich an die Syntaktische Analyse weitergegeben werden.

Definition 15: Lexer (bzw. Scanner)

Ein Lexer ist eine partielle Funktion $lex : \Sigma^* \to (N \times W)^*$, welche ein Wort aus Σ^* auf ein Token T mit einem Tokennamen N und einem Tokenwert W abbildet, falls diese Folge von Symbolen sich unter der regulären Grammatik G_{Lex} , der regulären Sprache L_{Lex} abbleiten lässt.

 a lecture-notes-2021.

Ein Lexer ist im Allgemeinen eine partielle Funktion, da es Zeichenfolgen geben kann, die kein Pattern eines Tokens der Sprache L_{Lex} matchen. In Bezug auf eine Implementierung, wird, wenn der Lexer Teil der Implementierung eines Compilers ist, in diesem Fall eine Fehlermeldung ausgegeben.

Eine weitere Aufgabe der Lekikalischen Analyse ist es jegliche für die Weiterverarbeitung unwichtigen Symbole, wie Leerzeichen $_{-}$, Newline \n^1 und Tabs \t aus dem Inputstring herauszufiltern. Das geschieht mittels des Lexers, der allen für die Syntaktische Analyse unwichtige Zeichen das leere Wort ϵ zuordnet. Das ist auch im Sinne der Definition, denn $\epsilon \in \Sigma^*$. Nur das, was für die Syntaktische Analyse wichtig ist, soll weiterverarbeitet werden, alles andere wird herausgefiltert.

Der Grund warum nicht einfach nur die Lexeme an die Syntaktische Analyse weitergegeben werden und der Grund für die Aufteilung des Tokens in Tokenname und Tokenwert ist, weil z.B. die Bezeichner von Variablen, Konstanten und Funktionen beliebige Zeichenfolgen sein können, wie my_fun, my_var oder my_const und es auch viele verschiedenen Zahlen gibt, wie 42, 314 oder 12. Die Überbegriffe bzw. Tokennamen für beliebige Bezeichner von Variablen, Konstanten und Funktionen und beliebige Zahlen sind aber trotz allem z.B. Zahl und Bezeichner.

Ein Lexeme ist damit aber nicht das gleiche, wie der Tokenwert, denn z.B. im Falle von PicoC kann z.B. der Wert 99 durch zwei verschiedene Literale darstellt werden, einmal als ASCII-Zeichen 'c' und des Weiteren auch in Dezimalschreibweise als 99². Der Tokenwert ist jedoch der letztendliche Wert an sich, unabhängig von der Darstellungsform.

Die Grammatik G_{Lex} , die zur Beschreibung der Token T einer regulären Sprache L_{Lex} verwendet wird, ist üblicherweise regulär, da ein typischer Lexer immer nur ein Symbol vorausschaut³, unabhängig davon, was für Symbole davor aufgetaucht sind. Die übliche Implementierung eines Lexers merkt sich nicht, was für Symbole davor aufgetaucht sind.

¹In Unix Systemen wird für Newline das ASCII Symbol line feed, in Windows hingegen die ASCII Symbole carriage return und line feed nacheinander verwendet. Das wird aber meist durch die verwendete Porgrammiersprache, die man zur Inplementierung des Lexers nutzt wegabstrahiert.

 $^{^2}$ Die Programmiersprache Python erlaubt es z.B. diesern Wert auch mit den Literalen 0b1100011 und 0x63 darzustellen.

³Man nennt das auch einem Lookahead von 1

Um Verwirrung verzubäugen ist es wichtig folgende Unterscheidung hervorzuheben: Wenn von Symbolen die Rede ist, so werden in der Lexikalischen Analyse, der Syntaktische Analyse und der Code Generierung, auf diesen verschiedenen Ebenen unterschiedliche Konzepte als Symbole bezeichnet.

In der Lexikalischen Analyse sind einzelne Zeichen eines Zeichensatzes die Symbole.

In der Syntaktischen Analyse sind die Tokennamen die Symbole.

In der Code Generierung sind die Bezeichner von Variablen, Konstanten und Funktionnen die Symbole^a.

^aDas ist der Grund, warum die Tabelle, in der Informationen zu Identifiern gespeichert werden aus Kapitel 3 Symboltabelle genannt wird.

Definition 16: Literal

Eine von möglicherweise vielen weiteren Darstellungsformen für ein und denselben Wert.

2.5 Syntaktische Analyse

In der Syntaktischen Analyse ist für einige Sprachen eine Kontextfreie Grammatik G_{Parse} notwendig, um diese Sprache zu beschreiben, da viele Programmiersprachen z.B. für Funktionsaufrufe fun(arg) und Codeblöcke if(1){} syntaktische Mittel verwenden, die es notwendig machen sich zu merken wieviele öffnende Klammern '(' bzw. öffnende geschweifte Klammern '{' es momentan gibt, die noch nicht durch eine enstsprechende schließende Klammer ')' bzw. schließende geschweifte Klammer '}' geschlossen wurden.

Die Syntax, in welcher der Inputstring aufgeschrieben ist, wird auch als Konkrette Syntax (Definition 17) bezeichnet. In einem Zwischenschritt, dem Parsen wird aus diesem Inputstring mithilfe eines Parsers (Definition 19), ein Derivation Tree (Definition 18) generiert, der als Zwischenstufe hin zum einem Abstrakt Syntax Tree (Definition 24) dient. Für einen ordentlichen Code ist es vor allem im Compilerbau förderlich kleinschrittig vorzugehen, deshalb erst die Generierung des Derivation Tree und dann der Abstrakt Syntax Tree.

Definition 17: Konkrette Syntax

Syntax einer Sprache, die durch die Grammatiken G_{Lex} und G_{Parse} zusammengenommen beschrieben wird.

Ein Programm in seiner Textrepräsentation, wie es in einer Textdatei nach den Produktionen der Grammatiken G_{Lex} und G_{Parse} abgeleitet steht, bevor man es kompiliert, ist in Konkretter Syntax aufgeschrieben.^a

^aCourse Webpage for Compilers (P423, P523, E313, and E513).

Definition 18: Derivation Tree (bzw. Parse Tree)

Compilerinterne Darstellung eines in Konkretter Syntax geschriebenen Inputstrings als Baumdatenstruktur, in der Nichtterminalsymbole die Inneren Knoten des Baumes und Terminalsymbole die Blätter des Baumes bilden. Jede Produktions der Grammatik G_{Parse} , die ein Teil der Konkrette Syntax ist, wird zu einem eigenen Knoten.

Der Derivation Tree wird optimalerweise immer so konstruiert bzw. die Konkrette Syntax immer so definiert, dass sich möglichst einfach ein Abstrakt Syntax Tree daraus konstruieren lässt.

Definition 19: Parser

Ein Programm, dass eine Eingabe in eine für die Weiterverbeitung taugliche Form bringt.

19.1: In Bezug auf Compilerbau ist ein Parser ein Programm, dass einen Inputstring von Konkretter Syntax in die compilerinterne Darstellung eines Derivation Tree übersetzt, was auch als Parsen bezeichnet wird^a.^b

"Es gibt allerdings auch alternative Definitionen, denen nach ein Parser in Bezug auf Compilerbau ein Programm ist, dass einen Inputstring von Konkretter Syntax in Abstrakte Syntax übersetzt. Im Folgenden wird allerdings die obigte Definition 19.1 verendet.

^bCompiler Design - Phases of Compiler.

An dieser Stelle könnte möglicherweise eine Begriffsverwirrung enstehen, ob ein Lexer nach der obigen Definition nicht auch ein Parser ist.

In Bezug auf Compilerbau ist ein Lexer ein Teil eines Parsers. Der Parser vereinigt sowohl die Lexikalische Analyse, als auch einen Teil der Syntaktischen Analyse in sich. Aber für sich isoliert, ohne Bezug zu Compilerbau betrachtet, ist ein Lexer nach Definition 19 ebenfalls ein Parser. Aber im Compilerbau hat Parser eine spezifischere Definition und hier überwiegt beim Lexer seine Funktionalität, dass er den Inputstring lexikalisch weiterverarbeitet, um ihn als Lexer zu bezeichnen, der Teil eines Parsers ist.

Die vom Lexer im Inputstring identifizierten Token werden in der Syntaktischen Analyse vom Parser (Definition 19) als Wegweiser verwendet, da je nachdem, in welcher Reihenfolge die Token auftauchen, dies einer anderen Ableitung in der Grammatik G_{Parse} entspricht. Dabei wird in der Grammatik nach dem Tokennamen unterschieden und nicht nach dem Tokenwert, da es nur von Interesse ist, ob an einer bestimmten Stelle z.B. eine Zahl steht und nicht, welchen konkretten Wert diese Zahl hat. Der Tokenwert ist erst später in der Code Generierung in 2.6 relevant.

Ein Parser ist einerseits ein erweiterter Recognizer, denn zum einen hat der Parser die Aufgabe eines Recognizers (Definition 20), und des Weiteren

Definition 20: Recognizer (bzw. Erkenner)

Entspricht dem Maschinenmodell eines Automaten. Im Bezug auf Compilerbau entspricht der Recognizer einem Kellerautomaten, in dem Wörter bestimmter Kontextfreier Sprachen erkannt werden. Der Recognizer erkennt, ob ein Iputstring bzw. Wort sich mit den Produktionen der Konkrette Syntax ableiten lässt, also ob er bzw. es Teil der Sprache ist, die von der Konkretten Syntax beschrieben wird oder nicht.

Für das Parsen gibt es verschiedene Ansätze:

- Top-Down Parsing:
 - asdf
- Buttom-Up Parsing: Es wird mit dem Inputstring gestartet und versucht diesen durch Rückwärtsanwenden der Produktionen der Konkretten Syntax bis zum Startsymbol zurückzuverfolgen.
 - asdf

Der Abstrakt Syntax Tree wird mithilfe von Transformern (Definition 21) und Visitors (Definition 22) generiert und ist das Endprodukt der Syntaktischen Analyse. Wenn man die gesamte Syntaktische Analyse betrachtet, so übersetzt diese einen Inpustring von der Konkretten Syntax in die Abstrakte Syntax (Definition 23).

Die Baumdatenstruktur des Derivation Tree und Abstrakt Syntax Tree ermöglicht es die Operationen, die der Compiler bei der Weiterverarbeitung des Inputstrings ausführen muss möglichst effizient auszuführen.

Definition 21: Transformer

Ein Programm, dass von unten-nach-oben, nach dem Breadth First Search Prinzip alle Knoten des Derivation Tree besucht und in Bezug zu Compilerbau, beim Antreffen eines bestimmten Knoten des Derivation Tree einen entsprechenden Knoten des Abstrakt Syntax Tree erzeugt und diesen anstelle des Knotens des Derivation Tree setzt und so Stück für Stück den Abstrak Syntax Tree konstruiert.

Definition 22: Visitor

Ein Programm, dass von unten-nach-oben, nach dem Breadth First Search Prinzip alle Knoten des Derivation Tree besucht und in Bezug zu Compilerbau, beim Antreffen eines bestimmten Knoten des Derivation Tree, diesen in-place mit anderen Knoten tauscht oder manipuliert, um den Derivation Tree für die weitere Verarbeitung durch z.B. einen Transformer zu vereinfachen.

Kann theoretisch auch zur Konstruktion eines Abstrakt Syntax Tree verwendet werden, wenn z.B. eine externe Klasse verwendet wird, welches für die Konstruktion des Abstrakt Syntax Tree verantwortlich ist, aber dafür ist ein Transformer besser geeignet.

Definition 23: Abstrakte Syntax

Syntax, die beschreibt, was für Arten von Komposition bei den Knoten eines Abstrakt Syntax Trees möglich sind.^a

Jene Produktionen, die in der Konkretten Syntax für die Umsetzung von Präzidenz notwendig waren, sind in der Abstrakten Syntax abgeflacht.

^aCourse Webpage for Compilers (P423, P523, E313, and E513).

Kapitel 2. Einführung 2.6. Code Generierung

Definition 24: Abstrakte Syntax Tree

Compilerinterne Darstellung eines Programs, in welcher sich anhand der Knoten auf dem Pfad von der Wurzel zu einem Blatt nicht mehr direkt nachvollziehen lässt, durch welche Produktionen dieses Blatt abgeleitet wurde.

Der Abstrakt Syntax Tree hat einmal den Zweck, dass die Kompositionen, die die Konten bilden können semantisch näher an den Instructions eines Assemblers dran sind und, dass man mit ihm bei der Betrachtung eines Knoten, der für einen Teil des Programms steht, möglichst schnell die Frage beantworten kann, welche Funktionalität der Sprache dieser umsetzt, welche Bestandteile er hat und welche Funktionalität der Sprache diese Bestandteile umsetzen usw.^a

^a Course Webpage for Compilers (P423, P523, E313, and E513).

Je weiter unten⁴ und links ein Knoten im Abstrakt Syntax Tree liegt, desto eher wird dieser Knoten komplett abgearbeitet sein, da in der Code Generierung die Knoten nach dem Depth First Search Prinzip abgearbeitet werden.

2.6 Code Generierung

Definition 25: Pass

2.7 Fehlermeldungen

Definition 26: Fehlermeldung

⁴In der Informatik wachsen Bäume von oben-nach-unten. Die Wurzel ist also oben.

3 Implementierung

3.1 Lexikalische Analyse

3.1.1 Verwendung von Lark

3.1.2 Basic Parser

3.2 Syntaktische Analyse

3.2.1 Verwendung von Lark

3.2.2 Umsetzung von Präzidenz

Die PicoC Sprache hat dieselben Präzidenzregeln implementiert, wie die Sprache C¹. Die Präzidenzregeln von PicoC sind in Tabelle 3.2.2 aufgelistet.

Präzidenz	Operator	Beschreibung	Assoziativität
1	a() a[] a.b	Funktionsaufruf Indexzugriff Attributzugriff	Links, dann rechts \rightarrow
2	−a !a ~a *a &a	Unäres Minus Logisches NOT und Bitweise NOT Dereferenz und Referenz, auch Adresse-von	Rechts, dann links \leftarrow
3	a*b a/b a%b	Multiplikation, Division und Modulo	Links, dann rechts \rightarrow
4	a+b a-b	Addition und Subtraktion	
5	a <b a<="b</td"><td>Kleiner, Kleiner Gleich, Größer, Größer gleich</td><td></td>	Kleiner, Kleiner Gleich, Größer, Größer gleich	
	a>b a>=b		
6	a==b a!=b	Gleichheit und Ungleichheit	
7	a&b	Bitweise UND	
8	a^b	Bitweise XOR (exclusive or)	
9	a b	Bitweise ODER (inclusive or)	
10	a&&b	Logiches UND	
11	a b	Logisches ODER	
12	a=b	Zuweisung	Rechts, dann links \leftarrow
13	a,b	Komma	Links, dann rechts \rightarrow

Tabelle 3.1: Präzidenzregeln von PicoC

 $^{^{1}}C\ Operator\ Precedence$ - cppreference.com.

- 3.2.3 Derivation Tree Generierung
- 3.2.4 Early Parser
- 3.2.5 Derivation Tree Vereinfachung
- 3.2.6 Abstrakt Syntax Tree Generierung

ASTNode

PicoC Nodes

RETI Nodes

- 3.3 Code Generierung
- 3.3.1 Passes

PicoC-Shrink Pass

PicoC-Blocks Pass

PicoC-Mon Pass

Definition 27: Symboltabelle

RETI-Blocks Pass

RETI-Patch Pass

RETI Pass

- 3.3.2 Umsetzung von Pointern und Arrays
- 3.3.3 Umsetzung von Structs
- 3.3.4 Umsetzung von Funktionen
- 3.3.5 Umsetzung kleinerer Details
- 3.4 Fehlermeldungen
- 3.4.1 Error Handler

4 Ergebnisse und Ausblick

- 4.1 Funktionsumfang
- 4.2 Qualitätskontrolle
- 4.3 Kommentierter Kompiliervorgang
- 4.4 Erweiterungsideen



- A.1 Konkrette und Abstrakte Syntax
- A.2 Bedienungsanleitungen
- A.2.1 PicoC-Compiler
- A.2.2 Showmode
- A.2.3 Entwicklertools

Literatur

Online

- C Operator Precedence cppreference.com. URL: https://en.cppreference.com/w/c/language/operator_precedence (besucht am 27.04.2022).
- Compiler Design Phases of Compiler. URL: https://www.tutorialspoint.com/compiler_design/compiler_design_phases_of_compiler.htm (besucht am 19.06.2022).
- Course Webpage for Compilers (P423, P523, E313, and E513). 28. Jan. 2022. URL: https://iucompilercourse.github.io/IU-Fall-2021/ (besucht am 28.01.2022).
- lecture-notes-2021. 20. Jan. 2022. URL: https://github.com/Compiler-Construction-Uni-Freiburg/lecture-notes-2021/blob/56300e6649e32f0594bbbd046a2e19351c57dd0c/material/lexical-analysis.pdf (besucht am 28.04.2022).
- What is the difference between a token and a lexeme? NewbeDEV. URL: http://newbedev.com/what-is-the-difference-between-a-token-and-a-lexeme (besucht am 17.06.2022).

19