
ALBERT LUDWIGS UNIVERSITÄT FREIBURG

TECHNISCHE FAKULTÄT

PicoC-Compiler

Übersetzung einer Untermenge von C in den Befehlssatz der RETI-CPU

BACHELORARBEIT

Abgabedatum: 28th April 2022

Author:
Jürgen Mattheis

Gutachter:
Prof. Dr. Scholl

Betreuung:
M.Sc. Seufert

Eine Bachelorarbeit am Lehrstuhl für
Betriebssysteme

ERKLÄRUNG

Hiermit erkläre ich, dass ich diese Abschlussarbeit selbständig verfasst habe, keine anderen als die angegebenen Quellen/Hilfsmittel verwendet habe und alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten Schriften entnommen wurden, als solche kenntlich gemacht habe. Darüber hinaus erkläre ich, dass diese Abschlussarbeit nicht, auch nicht auszugsweise, bereits für eine andere Prüfung angefertigt wurde.

Inhaltsverzeichnis

1	Motivation	6
1.1	PicoC und RETI	6
1.2	Problemstellung	6
1.3	Compiler und Interpreter	6
2	Einführung	7
2.1	Grammatiken	7
2.1.1	Konkrete Syntax	7
2.1.2	Chomsky Hierarchie	7
2.1.3	Reguläre Sprachen	7
2.1.4	Kontextfreie Sprachen	7
2.1.5	Präzedenz und Assoziativität	7
2.1.6	Mehrdeutige Grammatiken	7
2.1.7	Ableitungsbaum	7
2.1.8	Linksrekursiv und Rechtrekursiv	7
2.2	Lexikalische Analyse	7
2.3	Syntax Analyse	8
2.3.1	Derivation Tree	8
2.3.2	Abstrakte Syntax	8
2.3.3	Parser	8
2.3.4	Descent Parsing	8
2.3.5	First and Follow Set	8
2.3.6	Lookahead	8
2.3.7	Aktionen	8
2.4	Code Generation	8
2.4.1	Passes	8
2.4.2	T-Diagramme	8
2.5	Fehlermeldungen	8
2.5.1	Kategorien von Fehlermeldungen	8
3	Implementierung	9
3.1	Grammatiken	9
3.1.1	PicoC	9
3.1.2	RETI	10
3.1.3	Mehrdeutigkeit	10
3.1.4	Präzedenz und Assoziativität	10
3.1.5	Linksrekursivität	10
3.2	Lexikalische Analyse	10
3.2.1	Lark	10
3.2.2	LL(1) Recursive-Descent Lexer	10
3.3	Syntax Analyse	10
3.3.1	Lark	10
3.3.2	Normalized Heterogeneous ASTNode	10
3.3.3	Early Algorithmus	10
3.3.4	Visitor und Transformer	10
3.4	Code Generation	10

3.4.1	Symbol Table for Nested Scopes	10
3.4.2	PicoC-Shrink Pass	10
3.4.3	PicoC-Blocks Pass	10
3.4.4	PicoC-Mon Pass	10
3.4.5	RETI-Blocks Pass	10
3.4.6	RETI-Patch Pass	10
3.4.7	RETI Pass	10
3.5	Fehlermeldungen	10
3.5.1	Error Handler	10
4	Ergebnisse und Ausblick	11
4.1	Vergleich eigener Parser und Lark	11
4.2	Beispielhafte Ausführung	11
4.3	Qualitätskontrolle	11
4.4	Erweiterungsideen	11
A	Appendix	13

Abbildungsverzeichnis

Tabellenverzeichnis

3.1 Präzidenzregeln von PicoC	9
---	---

1 Motivation

1.1 PicoC und RETI

1.2 Problemstellung

1.3 Compiler und Interpreter

2 Einführung

2.1 Grammatiken

2.1.1 Konkrete Syntax

2.1.2 Chomsky Hierarchie

2.1.3 Reguläre Sprachen

2.1.4 Kontextfreie Sprachen

2.1.5 Präzedenz und Assoziativität

2.1.6 Mehrdeutige Grammatiken

2.1.7 Ableitungsbaum

2.1.8 Linksrekursiv und Rechtrekursiv

2.2 Lexikalische Analyse

Die **Lexikalische Analyse** bildet üblicherweise die erste Ebene innerhalb der **Pipe Architektur** bei der Implementierung von Compilern. Die Aufgabe der lexikalischen Analyse ist vereinfacht gesagt, in einem Inputstring, z.B. dem Inhalt einer Datei, welche in **UTF-8** codiert ist, Folgen endlicher Symbole (auch **Wörter** genannt) zu finden, die bestimmte **Pattern** (Definition 2.2.0.1) matchen, die durch eine **Grammatik** spezifiziert sind.

Definition 2.2.0.1: Pattern

Beschreibung aller möglichen **Lexeme** einer Menge \mathbb{P}_T , die einem bestimmten **Token** T zugeordnet werden. Die Menge \mathbb{P}_T ist eine möglicherweise unendliche Menge von **Wörtern**, die sich aus den Regeln einer **Grammatik** G einer **Sprache** L ableiten lassen, die für die Spezifikation eines **Tokens** zuständig sind.^a

^aWhat is the difference between a token and a lexeme?

Diese Folgen endlicher Symbole werden auch **Lexeme** (Definition 2.2.0.2) genannt.

Definition 2.2.0.2: Lexeme

Ein **Lexeme** ist ein **Wort** aus dem Inputstring, welches das **Pattern** für eines der **Token** einer **Sprache** L matched.^a

^aWhat is the difference between a token and a lexeme?

Diese **Lexeme** werden vom **Lexer** im Inputstring identifiziert und **Tokens** zugeordnet (Definition 2.2.0.3).

Definition 2.2.0.3: Lexer (bzw. Scanner)

Ein **Lexer** ist eine *rechtseindeutige Funktion* $lex : \Sigma^* \rightarrow (N \times V)^*$, welche ein **Wort** aus Σ^* auf ein **Token** von einem **Token Name** N und einem **Token Value** V abbildet, falls Folge von Symbolen sich unter der Grammatik G der **Sprache** L ableiten lässt.^a

^alecture-notes-2021.

Ein Token

test

2.3 Syntax Analyse

2.3.1 Derivation Tree

2.3.2 Abstrakte Syntax

2.3.3 Parser

2.3.4 Descent Parsing

2.3.5 First and Follow Set

2.3.6 Lookahead

2.3.7 Aktionen

2.4 Code Generation

2.4.1 Passes

2.4.2 T-Diagramme

2.5 Fehlermeldungen

2.5.1 Kategorien von Fehlermeldungen

3 Implementierung

3.1 Grammatiken

3.1.1 PicoC

Die PicoC Sprache hat dieselben Präzidenzregeln implementiert, wie die Sprache C¹. Die Präzidenzregeln von PicoC sind in Tabelle 3.1.1 aufgelistet.

Präzidenz	Operator	Beschreibung	Assoziativität
1	a() a[] a.b	Funktionsaufruf Indezzugriff Attributzugriff	Links, dann rechts →
2	-a !a ~a *a &a	Unäres Minus Logisches NOT und Bitweise NOT Dereferenz und Referenz, auch Adresse-von	Rechts, dann links ←
3	a*b a/b a%b	Multiplikation, Division und Modulo	Links, dann rechts →
4	a+b a-b	Addition und Subtraktion	
5	a<b a<=b a>b a>=b	Kleiner, Kleiner Gleich, Größer, Größer gleich	
6	a==b a!=b	Gleichheit und Ungleichheit	
7	a&b	Bitweise UND	
8	a^b	Bitweise XOR (exclusive or)	
9	a b	Bitweise ODER (inclusive or)	
10	a&&b	Logisches UND	
11	a b	Logisches ODER	
12	a=b	Zuweisung	Rechts, dann links ←
13	a,b	Komma	Links, dann rechts →

Tabelle 3.1: Präzidenzregeln von PicoC

¹ C Operator Precedence - cppreference.com.

3.1.2 RETI

3.1.3 Mehrdeutigkeit

3.1.4 Präzidenz und Assoziativität

3.1.5 Linksrekursivität

3.2 Lexikalische Analyse

3.2.1 Lark

3.2.2 LL(1) Recursive-Descent Lexer

3.3 Syntax Analyse

3.3.1 Lark

3.3.2 Normalized Heterogeneous ASTNode

3.3.3 Early Algorithmus

Das LL(k) Recursive-Descent Parser² Pattern ist

3.3.4 Visitor und Transformer

3.4 Code Generation

3.4.1 Symbol Table for Nested Scopes

3.4.2 PicoC-Shrink Pass

3.4.3 PicoC-Blocks Pass

3.4.4 PicoC-Mon Pass

3.4.5 RETI-Blocks Pass

3.4.6 RETI-Patch Pass

3.4.7 RETI Pass

3.5 Fehlermeldungen

3.5.1 Error Handler

²Parr, *Language Implementation Patterns*.

4 Ergebnisse und Ausblick

4.1 Vergleich eigener Parser und Lark

4.2 Beispielhafte Ausführung

4.3 Qualitätskontrolle

4.4 Erweiterungsideen

Test, ob der Spellchecker funktioniert Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor.

Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

A Appendix

Literatur

Online

- *C Operator Precedence* - *cppreference.com*. URL: https://en.cppreference.com/w/c/language/operator_precedence (besucht am 27.04.2022).
- *lecture-notes-2021*. 20. Jan. 2022. URL: <https://github.com/Compiler-Construction-Uni-Freiburg/lecture-notes-2021/blob/56300e6649e32f0594bbbd046a2e19351c57dd0c/material/lexical-analysis.pdf> (besucht am 28.04.2022).
- *What is the difference between a token and a lexeme?* NewbeDEV. URL: <http://newbedev.com/what-is-the-difference-between-a-token-and-a-lexeme> (besucht am 17.06.2022).