Albert Ludwigs Universität Freiburg

TECHNISCHE FAKULTÄT

PicoC-Compiler

Übersetzung einer Untermenge von C in den Befehlssatz der RETI-CPU

BACHELORARBEIT

Abgabedatum: 13. September 2022

Autor: Jürgen Mattheis

Gutachter: Prof. Dr. Scholl

Betreung: M.Sc. Seufert

Eine Bachelorarbeit am Lehrstuhl für

Betriebssysteme

ERKLÄRUNG

Hiermit erkläre ich, dass ich diese Abschlussarbeit selbständig verfasst habe, keine anderen als die angegebenen Quellen/Hilfsmittel verwendet habe und alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten Schriften entnommen wurden, als solche kenntlich gemacht habe. Darüber hinaus erkläre ich, dass diese Abschlussarbeit nicht, auch nicht auszugsweise, bereits für eine andere Prüfung angefertigt wurde.

Danksagungen

Bevor der Inhalt dieser Schrifftlichen Ausarbeitung der Bachelorarbeit anfängt, will ich einigen Personen noch meinen Dank aussprechen.

Ich schreibe die folgenden Danksagungen nicht auf eine bestimmte Weise, wie es sich vielleicht etabliert haben sollte Danksagungen zu schreiben und verwende auch keine künstlichen Floskeln, wie "mein aufrichtigster Dank" oder "aus tiefstem Herzen", sondern drücke im Folgenden die Dinge nur so aus, wie ich sie auch wirklich meine.

Estmal, ich hatte selten im Studium das Gefühl irgendwo Kunde zu sein, aber bei dieser Bachelorarbeit und dem vorangegangenen Bachelorprojekt hatte ich genau diese Gefühl, obwohl die Verhältnisse eigentlich genau umgekehrt sein sollten. Die Umgang mit mir wahr echt unglaublich nett und unbürokratisch, was ich als keine Selbverständlichkeit ansehe und sehr wertgeschätzt habe.

An erster Stelle will ich zu meinem Betreuer M.Sc. Tobias Seufert kommen, der netterweise auch bereits die Betreuung meines Bachelorprojektes übernommen hatte. Wie auch während des Bachelorprojektes, haben wir uns auch bei den Meetings während der Bachelorarbeit hervorragend verstanden. Dabei ging die Freundlichkeit und das Engagement seitens Tobias weit über das heraus, was man bereits als eine gute Betreuung bezeichnen würde.

Es gibt verschiedene Typen von Menschen, es gibt Leute, die nur genauso viel tun, wie es die Anforderungen verlangen und nichts darüberhinaus tun, wenn es nicht einen eigenen Vorteil für sie hat und es gibt Personen, die sich für nichts zu Schade sind und dies aus einer Philanthropie oder Leidenschafft heraus tun, auch wenn es für sie keine Vorteile hat. Tobias¹ konnte ich während der langen Zeit, die er mein Bachelorprojekt und dann meine Bachelorarbeit betreut hat eindeutig als letzteren Typ Mensch einordnen.

Er war sich nie zu Schade für meine vielen Fragen während der Meetings, auch wenn ich meine Zeit ziemlich oft überzogen habe², er hat sich bei der Korrektur dieser Schrifftlichen Ausarbeitung sogar die Mühe gemacht bei den einzelnen Problemstellen längere, wirklich hilfreiche Textkommentare zu verfassen und obendrauf auch noch Tippfehler usw. angemerkt und war sich nicht zu Schade die Rolle des Nachrichtenübermittlers zwischen mir und Prof. Dr. Scholl zu übernehmen. All dies war absolut keine Selbverständlichkeit, vor allem wenn ich die Betreuung anderer Studenten, die ich kenne mit der vergleiche, die mir zu Teil wurde.

An den Kommentar zu meinem Betreuer Tobias will ich einen Kommentar zu meinem Gutachter Prof. Dr. Scholl anschließen. Wofür ich meinem Gutachter Prof. Dr. Scholl sehr dankbar bin, ist, dass er meine damals sehr ambitionierten Ideen für mögliche Funktionalitäten, die ich in den PicoC-Compiler für die Bachelorarbeit implementierten wollte runtergeschraubt hat. Man erlebt es äußerst selten im Studium, dass Studenten freiwillig weniger Arbeit gegeben wird.

Bei den für die Bachelorarbeit zu implementierenden Funktionalitäten gab es bei der Implementierung viele unerwartete kleine Details, die ich vorher garnicht bedacht hatte, die in ihrer Masse unerwartet viel Zeit zum Implementieren gebraucht haben. Mit den von Prof. Dr. Scholl festgelegten Funktionalitäten für die Bachelorarbeit ist der Zeitplan jedoch ziemlich perfekt aufgegangen. Mit meinen ambitionierten Plänen wäre es bei der Bachelorarbeit dagegeben wohl mit der Zeit äußerst kritisch geworden. Das Prof. Dr. Scholl mir zu

¹Wie auch Prof. Dr. Scholl. Hier geht es aber erstmal um Tobias.

²Wofür ich mich auch nochmal Entschuldigen will.

seinem eigenen Nachteil 3 weniger Arbeit aufgebrummt hat empfand ich als ich eine äußerst nette Geste, die ich sehr geschätzt habe.

Wie mein Betreuer M.Sc. Tobias Seufert und wahrscheinlich auch mein Gutachter Prof. Dr. Scholl im Verlauf dieser Bachelorarbeit und des vorangegangenen Bachelorprojektes gemerkt haben, kann ich schon manchmal ziemlich eigensinnigen sein, bei der Weise, wie ich bestimmte Dinge umsetzen will. Ich habe es sehr geschätzt, dass mir das durchgehen gelassen wurde. Es ist, wie ich die Universitätswelt als Student erlebe bei Arbeitsvorgaben keine Selbverständlichkeit, dass dem Studenten überhaupt die Freiheit und das Vertrauen gegeben wird diese auf seine eigenen Weise umzusetzen.

Vor allem, da mein eigenes Vorgehen größtenteils Vorteile für mich hatte, da ich auf diese Weise am meisten über Compilerbau gelernt hab und eher Nachteile für Prof. Dr. Scholl, da mein eigenes Vorgehen entsprechend mehr Zeit brauchte und ich daher als Bachelorarbeit keinen dazu passenden RETI-Emulator mit Graphischer Anzeige implementieren konnte, da die restlichen Funktionalitäten des PicoC-Compilers noch implementiert werden mussten.

Glücklicherweise gibt es aber doch noch einen passenden RETI-Emulator, der den PicoC-Compiler über seine Kommandozeilenargumente aufruft, um ein PicoC-Programm visuell auf einer RETI-CPU auszuführen. Für dessen Implementierung hat sich Michel Giehl netterweise zur Verfügung gestellt. Daher Danke auch an Michel Giehl, dass er sich mit meinem PicoC-Compiler ausgeinandergesetzt hat und diesen in seinen RETI-Emulator integriert hat, sodass am Ende durch unsere beiden Arbeiten ein anschauliches Lerntool für die kommenden Studentengenerationen entstehen konnte. Vor allem da er auch mir darin vertrauen musste, dass ich mit meinem PicoC-Compiler nicht irgendeinen Misst baue. Der RETI-Emulator von Michel Giehl ist unter Link⁵ zu finden.

Mir hat die Implementierung des PicoC-Compilers tatsächlich ziemlich viel Spaß gemacht, da Compilerbau auch in mein perönliches Interessengebiet fällt⁶. Das Aufschreiben dieser Schrifftlichen Ausarbeitung hat mir dagegen eher weniger Spaß gemacht⁷. Wobei ich allerdings sagen muss, dass ich eine große Erleichterung verspüre das ganze Wissen über Compilerbau mal aufgeschrieben zu haben, damit ich mir keine Sorgen machen muss dieses ziemlich nützliche Wissen irgendwann wieder zu vergessen. Es hilft einem auch als Programmierer ungemein weiter zu wissen, wie ein Compiler unter der Haube funktioniert, da man sich so viel besser merken, wie eine bestimmte Funktionalität einer Programmiersprache zu verwenden ist. Manch eine Funktionalität einer Programmiesprache kann in der Verwendung ziemlich wilkürlich erscheinen, wenn man die technische Umsetzung dahinter im Compiler nicht kennt.

Ich wollte mich daher auch noch dafür Bedanken, dass mir ein so ergiebiges und interessantes Thema als Bachelorarbeit vorgeschlagen wurde und vor allem, dass auch das Vertrauen in mich gesteckt wurde, dass ich am Ende auch einen funktionsfähigen, sauber programmierten und gut durchdachten Compiler implementiere.

Zum Schluss nochmal ein abschließendes Danke an meinen Betreuer M.Sc Seufert und meinen Gutachter Prof. Dr. Scholl für die Betreuung und Bereitstellung dieser interessanten Bachelorarbeit und des vorangegangenen Bachelorprojektes und Michel Giehl für das Integrieren des PicoC-Compilers in seinen RETI-Emulator.

³Der PicoC-Compiler hätte schließlich mehr Funktionalitäten haben können.

⁴Vielleicht finde ich ja noch im nächsten Semester während des Betriebssysteme Tutorats noch etwas Zeit einige weitere Features einzubauen oder möglicherweise im Rahmen eines Masterprojektes ³.

 $^{^5}$ https://github.com/michel-giehl/Reti-Emulator.

⁶Womit nicht alle Studenten so viel Glück haben.

⁷Dieses ständige überlegen, wo man möglicherweise eine Erklärlücke hat, ob man nicht was wichtiges ausgelassen hat usw.

Inhaltsverzeichnis

Abbildungsverzeichnis	I
Codeverzeichnis	II
Tabellenverzeichnis	III
Definitionsverzeichnis	IV
Grammatikverzeichnis	V
	A A C H
Literatur	\mathbf{L}

Abbildungsverzeichnis

1.1	Datenpfade der RETI-Architektur aus C. Scholl, "Betriebssysteme", nicht selbst erstellt	(
1.2	Cross-Compiler als Bootstrap Compiler	
1.3	Iteratives Bootstrapping	k

Codeverzeichnis

Tabellenverzeichnis

1.1	Load und Store Befehle aus C. Scholl, "Betriebssysteme", nicht selbst zusammengestellt, leicht	
	abgewandelt	Α
1.2	Compute Befehle aus C. Scholl, "Betriebssysteme", nicht selbst zusammengestellt, leicht	
	abgewandelt	В
1.3	Jump Befehle aus C. Scholl, "Betriebssysteme", nicht selbst zusammengestellt, leicht abgewandelt.	В

Definitionsverzeichnis

1.1	Bezeichner (bzw. Identifier)
1.2	Label (
1.3	Assemblersprache (bzw. engl. Assembly Language)
1.4	Assembler
1.5	Objektcode
1.6	Linker
1.7	Transpiler (bzw. Source-to-source Compiler)
1.8	Rekursiver Abstieg
1.9	Linksrekursive Grammatiken
1.10	$LL(k)\text{-}Grammatik \qquad $
1.11	Earley Erkenner
1.12	Liveness Analyse
1.13	Live Variable
1.14	Graph Coloring
	Interference Graph
	Kontrollflussgraph
	Kontrollfluss
	Kontrollflussanalyse
	Two-Space Copying Collector
	Self-compiling Compiler
	Bootstrapping
	Boostrap Compiler
1.23	Minimaler Compiler

Grammatikverzeichnis

Appendix

Dieses Kapitel dient als Lagerstätte für Definitionen, Tabellen, Abbildungen und ganze Unterkapitel, die zum Erhalt des roten Fadens und des Leseflusses in den vorangegangenen Kapiteln hierher ausgelaggert wurden. Im Unterkapitel RETI Architektur Details können einige Details der RETI-Architektur nachgeschaut werden, die im Kapitel ?? den Lesefluss stören würden und zum Verständnis nur bedingt wichtig sind. Im Unterkapitel Sonstige Definitionen sind einige Definitionen ausgelaggert, die zum Verständnis der Implementierung des PicoC-Compilers nicht wichtig sind, aber z.B. an einer bestimmten Stelle in den vorangegangenen Kapiteln kurz Erwähnung fanden. Im Unterkapitel Bootstrapping wird ein Vorgehen, das Bootstrapping erklärt, welches beim PicoC-Compiler nicht umgesetzt wurde, es aber erlauben würde aus dem PicoC-Compiler einen Compiler für die RETI-CPU zu machen, der auf der RETI-CPU selbst läuft.

RETI Architektur Details

Hier wird die Semantik der verschiedenen Befehle des Befehlssatzes der RETI-Architektur mithilfe von Tabelle 1.1, Tabelle 1.2 und Tabelle 1.3 dokumentiert. Des Weiteren sind in Abbildung 1.1 die Datenpfade der RETI-Architektur dargestellt.

Typ	\mathbf{Modus}	Befehl	Wirkung
01	00	LOAD D i	$D := M(\langle i \rangle), \langle PC \rangle := \langle PC \rangle + 1$
01	01	LOADIN S D i	$D := M(\langle S \rangle + i), \langle PC \rangle := \langle PC \rangle + 1$
01	11	LOADI D i	$D := 0^{10}i, \langle PC \rangle := \langle PC \rangle + 1, \text{ bei } D = PC \text{ wird der PC}$
			nicht inkrementiert
10	00	STORE S i	$M(\langle i \rangle) := S, \langle PC \rangle := \langle PC \rangle + 1$
10	01	STOREIN D S i	$M(\langle D \rangle + i) := S, \langle PC \rangle := \langle PC \rangle + 1$
10	11	MOVE S D	$D := S, \langle PC \rangle := \langle PC \rangle + 1$, Move: Bei $D = PC$ wird der
			PC nicht inkrementiert

Tabelle 1.1: Load und Store Befehle aus C. Scholl, "Betriebssysteme", nicht selbst zusammengestellt, leicht abgewandelt.

Typ	M	RO	F	Befehl	Wirkung
00	0	0	000	ADDI D i	$[D] := [D] + [i], \langle PC \rangle := \langle PC \rangle + 1$
00	0	0	001	SUBI D i	$[D] := [D] - [i], \langle PC \rangle := \langle PC \rangle + 1$
00	0	0	010	MULI D i	$[D] := [D] * [i], \langle PC \rangle := \langle PC \rangle + 1$
00	0	0	011	DIVI D i	$[D] := [D] / [i], \langle PC \rangle := \langle PC \rangle + 1$
00	0	0	100	MODI D i	$[D] := [D] \% [i], \langle PC \rangle := \langle PC \rangle + 1$
00	0	0	101	OPLUSI D i	$[D] := [D] \oplus 0^{10}i, \langle PC \rangle := \langle PC \rangle + 1$
00	0	0	110	ORI D i	$[D] := [D] \lor 0^{10}i, \langle PC \rangle := \langle PC \rangle + 1$
00	0	0	101	ANDI D i	$[D] := [D] \wedge 0^{10}i, \langle PC \rangle := \langle PC \rangle + 1$
00	1	0	000	ADD D i	$[D] := [D] + [M(\langle i \rangle)], \langle PC \rangle := \langle PC \rangle + 1$
00	1	0	001	SUB D i	$[D] := [D] - [M(\langle i \rangle)], \langle PC \rangle := \langle PC \rangle + 1$
00	1	0	010	MUL D i	$[D] := [D] * [M(\langle i \rangle)], \langle PC \rangle := \langle PC \rangle + 1$
00	1	0	011	DIV D i	$[D] := [D] / [M(\langle i \rangle)], \langle PC \rangle := \langle PC \rangle + 1$
00	1	0	100	MOD D i	$[D] := [D] \% [M(\langle i \rangle)], \langle PC \rangle := \langle PC \rangle + 1$
00	1	0	101	OPLUS D i	$D := D \oplus M(\langle i \rangle), \langle PC \rangle := \langle PC \rangle + 1$
00	1	0	110	OR D i	$D := D \vee M(\langle i \rangle), \langle PC \rangle := \langle PC \rangle + 1$
00	1	0	101	AND D i	$D := D \land M(\langle i \rangle), \langle PC \rangle := \langle PC \rangle + 1$
00	*	1	000	ADD D S	$[D] := [D] + [S], \langle PC \rangle := \langle PC \rangle + 1$
00	*	1	001	SUB D S	$[D] := [D] - [S], \langle PC \rangle := \langle PC \rangle + 1$
00	*	1	010	MUL D S	$[D] := [D] * [S], \langle PC \rangle := \langle PC \rangle + 1$
00	*	1	011	DIV D S	$[D] := [D] / [S], \langle PC \rangle := \langle PC \rangle + 1$
00	*	1	100	MOD D S	$[D] := [D] \% [S], \langle PC \rangle := \langle PC \rangle + 1$
00	*	1	101	OPLUS D S	$D := D \oplus S, \langle PC \rangle := \langle PC \rangle + 1$
00	*	1	110	OR D S	$D := D \lor S, \langle PC \rangle := \langle PC \rangle + 1$
00	*	1	101	AND D S	$D := D \land S, \langle PC \rangle := \langle PC \rangle + 1$

Tabelle 1.2: Compute Befehle aus C. Scholl, "Betriebssysteme", nicht selbst zusammengestellt, leicht abgewandelt.

Type	Condition	J	Befehl	Wirkung
11	000	00	NOP	$\langle PC \rangle := \langle PC \rangle + 1$
11	001	00	$\mathrm{JUMP}_{>}\mathrm{i}$	Falls $[ACC] > 0$: $\langle PC \rangle := \langle PC \rangle + [i]$, sonst: $\langle PC \rangle := \langle PC \rangle + 1$
11	010	00	$JUMP_{=}i$	Falls $[ACC] = 0$: $\langle PC \rangle := \langle PC \rangle + [i]$, sonst: $\langle PC \rangle := \langle PC \rangle + 1$
11	011	00	$\mathrm{JUMP}_{\geq}\mathrm{i}$	Falls $[ACC] \ge 0$: $\langle PC \rangle := \langle PC \rangle + [i]$, sonst: $\langle PC \rangle := \langle PC \rangle + 1$
11	100	00	$JUMP_{<}i$	Falls $[ACC] < 0$: $\langle PC \rangle := \langle PC \rangle + [i]$, sonst: $\langle PC \rangle := \langle PC \rangle + 1$
11	101	00	$\mathrm{JUMP}_{ eq}\mathrm{i}$	Falls $[ACC] \neq 0$: $\langle PC \rangle := \langle PC \rangle + [i]$, sonst: $\langle PC \rangle := \langle PC \rangle + 1$
11	110	00	$JUMP \le i$	Falls $[ACC] \le 0$: $\langle PC \rangle := \langle PC \rangle + [i]$, sonst: $\langle PC \rangle := \langle PC \rangle + 1 \langle PC \rangle := \langle PC \rangle + [i]$
11	111	00	JUMPi	$\langle PC \rangle := \langle PC \rangle + [i]$
11	*	01	INT i	$\langle PC \rangle := IVT[i]$ Interrupt Nr.i wird Ausgeführt
11	*	10	RTI	Rücksprungadresse vom Stack entfernt, in PC geladen, Wechsel in Usermodus

 $\textbf{Tabelle 1.3:} \ \textit{Jump Befehle aus C. Scholl, "Betriebssysteme", nicht selbst zusammengestellt, leicht abgewandelt.$

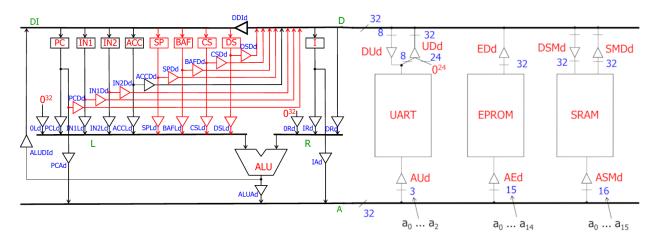


Abbildung 1.1: Datenpfade der RETI-Architektur aus C. Scholl, "Betriebssysteme", nicht selbst erstellt.

Sonstige Definitionen

Im Folgenden sind einige Definitionen aufgelistet, die in den vorangegangenen Kapiteln Erwähnung fanden und zur Beibehaltung des roten Fadens und des Leseflusses in dieses Unterkapitel ausgelaggert wurden. Die Definitionen in diesem Unterkapitel vermitteln Theorie über Compilerbau, die über das hinausgeht, was zum Verständnis der Implementierung des PicoC-Compilers notwendig ist.

Definition 1.1: Bezeichner (bzw. Identifier)

I

Zeichenfolge^a, die eine Konstante, Variable, Funktion usw. innerhalb ihres Sichtbarkeitsbereichs (Definition ??) eindeutig benennt. bc

Definition 1.2: Label

1

Durch einen Bezeichner eindeutig zuordenbares Sprungziel im Programmcode. a

^aThiemann, "Compilerbau".

Definition 1.3: Assemblersprache (bzw. engl. Assembly Language)



Eine sehr hardwarenahe Programmiersprache, deren Befehle eine starke Entsprechung zu bestimmten Maschinenbefehlen bzw. Folgen von Maschinenbefehlen haben. Viele Befehle haben eine ähnliche übliche Struktur Operation <Operanden>, mit einer Operation, die einen Opcode eines Maschinenbefehls bezeichnet und keinen oder mehreren Operanden, so wie die Maschinenbefehle, denen sie entsprechen. Allerdings gibt es oftmals noch viel "syntaktischen Zucker" innerhalb der Befehle und drumherum". d

^aBzw. Tokenwert.

^bAußer wenn z.B. bei Methoden die Programmiersprache das Überladen erlaubt usw. In diesem Fall wird die Signatur der Funktion als weiteres Unterscheidungsmerkmal hinzugenommen, damit es eindeutig ist.

^cThiemann, "Einführung in die Programmierung".

^aBefehle der Assemblersprache, die mehreren Maschinenbefehlen entsprechen werden auch als Pseudo-Befehle bezeichnet und entsprechen dem, was man im allgemeinen als Macro bezeichnet.

 $^{{}^{}b}$ Z.B. erlaubt die Assemblersprache des GCC für die X_{86_64} -Architektur für manche Operanden die Syntax n(%r), die einen Speicherzugriff mit Offset n zur Adresse, die im Register %r steht durchführt, wobei z.B. die Klammern () usw. nur "syntaktischer Zucker" sind und natürlich nicht mitkodiert werden.

 c Z.B. sind im $X_{86.64}$ -Assembler die Befehle in Blöcken untergebracht, die ein Label haben und zu denen mittels jmp <label> gesprungen werden kann. Ein solches Konstrukt, was vor allem auch noch relativ beliebig wählbare Bezeichner verwendet, hat keine direkte Entsprechung in einem handelsüblichen Prozessor oder Hauptspeicher.

^dP. Scholl, "Einführung in Embedded Systems".

Anmerkung Q

Ein Assembler (Definition 1.4) ist in üblichen Compilern in einer bestimmten Form meist schon integriert, da Compiler üblicherweise direkt Maschinencode bzw. Objektcode (Definition 1.5) erzeugen. Ein Compiler soll möglichst viel von seiner internen Funktionsweise und der damit verbundenen Theorie für den Benutzer abstrahieren und dem Benutzer daher standardmäßig einfach nur die Ausgabe liefern, welche er in den allermeisten Fällen haben will, nämlich den Maschinencode, der direkt ausführbar ist bzw. den Objektcode der ausführbar ist, wenn er später mit dem Linker (Definition 1.6) zu Maschinencode zusammengesetzt wird.

Definition 1.4: Assembler

/

Übersetzt im allgemeinen Assemblercode in Assemblersprache zu Maschinencode bzw. Objektcode in Maschinensprache. Der Maschinencode und Objektcode werden üblicherweise beide in binärer Repräsentation erzeugt. a

^aP. Scholl, "Einführung in Embedded Systems".

Definition 1.5: Objektcode



Bei Komplexeren Compilern, die es erlauben den Programmcode in mehrere Dateien aufzuteilen, wird häufig Objektcode erzeugt, der neben der Folge von Maschinenbefehlen in binärer Repräsentation auch noch Informationen für den Linker enthält, die im späteren Maschinencode nicht mehr enthalten sind, sobald der Linker die Objektdateien zum Maschinencode zusammengesetzt hat.^a

^aP. Scholl, "Einführung in Embedded Systems".

Definition 1.6: Linker

!

Programm, dass Objektcode aus mehreren Objektdateien zu ausführbarem Maschinencode in eine ausführbare Datei oder Bibliotheksdatei linkt bzw. zusammenfügt und Adresseresolution macht, sodass unter anderem kein vermeidbarer doppelter Code darin vorkommt.^a

^aP. Scholl, "Einführung in Embedded Systems".

Definition 1.7: Transpiler (bzw. Source-to-source Compiler)

Z

Kompiliert zwischen Sprachen, die ungefähr auf dem gleichen Level an Abstraktion arbeiten^a.^b

^aEin gutes Beispiel hierfür ist die Programmiersprache TypeScript, die als Obermenge von JavaScript die Sprache Javascript erweitern will und gleichzeitig die Syntax von JavaScript unterstützen will. Daher bietet es sich an Typescript zu Javascript zu transpilieren.

^bThiemann, "Compilerbau".

Definition 1.8: Rekursiver Abstieg

1

Es wird jedem Nicht-Terminalsymbol eine Prozedur zugeordnet, welche die Produktionen dieses Nicht-Terminalsymbols umsetzt. Prozeduren rufen sich dabei wechselseitig entsprechend der Produktionen, welche sie jeweils umsetzen gegenseitig auf.

Anmerkung Q

Bei manchen Ansätzen für das Parsen eines Programmes, ist es notwendig eine LL(k)-Grammatik (Definition 1.10) vorliegen zu haben. Bei diesen Ansätzen, die meist die Methode des Rekursiven Abstiegs (Definition 1.8) verwenden, lässt sich eine bessere minimale Laufzeit garantieren, da aufgrund der LL(k)-Eigenschafft ausgeschlossen werden kann, dass Backtracking notwendig ist^a.

Manche der Ansätze für das Parsen eines Programmes haben ein Problem, wenn die Grammatik, die beim Algorithmus zur Entscheidung des Wortproblems verwendet wird, eine Linksrekursive Grammatik (Definition 1.9) ist^b.

Definition 1.9: Linksrekursive Grammatiken

7

 $Eine\ Grammatik\ ist\ linksrekursiv,\ wenn\ sie\ ein\ Nicht-Terminal symbol\ enthält,\ dass\ linksrekursiv\ ist$

Ein Nicht-Terminalsymbol ist linksrekursiv, wenn das linkeste Symbol in einer seiner Produktionen es selbst ist oder zu sich selbst gemacht werden kann durch eine Folge von Ableitungen:

$$A \Rightarrow^* Aa$$
,

wobei a eine beliebige Folge von Grammatiksymbolen^a ist.^b

Definition 1.10: LL(k)-Grammatik

1

Eine Grammatik ist LL(k) für $k \in \mathbb{N}$, falls jeder Ableitungsschritt eindeutig durch die nächsten k Tokentypen der Tokens, welche aus dem Eingabewort generiert wurden bestimmt werden k ann a. Dabei steht LL für left-to-right und leftmost-derivation, da das Eingabewort von links nach rechts geparst und immer Linksableitungen genommen werden müssen a, damit die obige Bedingung mit den nächsten a Symbolen gilt. a

Definition 1.11: Earley Erkenner

Z

Ist ein Erkenner (Definition ??), der für alle Kontextfreien Sprachen das Wortproblem entscheiden kann und das mittels Dynamischer Programmierung mit dem Top-Down Ansatz (siehe Unterkapitel ??) umsetzt. abc

^aMehr Erklärung hierzu findet sich im Unterkapitel ??.

^bFür den im PicoC-Compiler verwendeten Earley Parsers stellt dies allerdings kein Problem dar.

^aAlso eine beliebige Folge von Terminalsymbolen und Nicht-Terminalsymbolen.

^bParsers — Lark documentation.

^aDas wird auch als Lookahead von k bezeichnet.

^bWobei sich das mit den Linksableitungen automatisch ergibt, wenn man das Eingabewort von links-nach-rechts parsed und jeder der nächsten k Ableitungsschritte eindeutig sein soll.

^cNebel, "Theoretische Informatik".

Eingabe und Ausgabe des Algorithmus sind:

- Eingabe: Eingabewort w und Konkrete Grammatik $G_{Parse} = \langle N, \Sigma, P, S \rangle$.
- Ausgabe: 0 wenn $w \notin L(G_{Parse})$ und 1 wenn $w \in L(G_{Parse})$.

Bevor dieser Algorithmus erklärt wird, müssen noch einige Symbole und Notationen erklärt werden:

- α , β , γ stellen eine beliebige Folge von Grammatiksymbolen^e dar.
- A und B stellen Nicht-Terminalsymbole dar.
- a stellt ein Terminalsymbol dar.
- Earley's Punktnotation: $A := \alpha \bullet \beta$ stellt eine Produktion, in der α bereits geparst wurde und β noch geparst werden muss.
- Die Indexierung ist informell ausgedrückt so umgesetzt, dass die Indices zwischen Tokentypen liegen, also Index 0 vor dem ersten Tokentyp verortet ist, Index 1 nach dem ersten Tokentyp verortet ist und Index n nach dem letzten Tokentyp verortet ist.

und davor müssen noch einige Begriffe definiert werden:

- Zustandsmenge: Für jeden der n+1 Indices j wird eine Zustandsmenge Z(j) generiert.
- Zustand einer Zustandsmenge: Ist ein Tupel $(A := \alpha \bullet \beta, i)$, wobei $A := \alpha \bullet \beta$ die aktuelle Produktion ist, die bis Punkt \bullet geparst wurde und i der Index ist, ab welchem der Versuch der Erkennung eines Teilworts des Eingabeworts mithilfe dieser Produktion begann.

Der Ablauf des Algorithmus ist wie folgt:

- 1. initialisiere Z(0) mit der Produktion, welches das Startsymbol S auf der linken Seite des ::=-Symbols hat.
- 2. es werden in der aktuellen Zustandsmenge Z(j) die folgenden Operationen ausgeführt:
 - Voraussage: Für jeden Zustand in der Zustandsmenge Z(j), der die Form $(A ::= \alpha \bullet B\gamma, i)$ hat, wird für jede Produktion $(B ::= \beta)$ in der Konkreten Grammatik, die ein B auf der linken Seite des ::=-Symbols hat ein Zustand $(B ::= \bullet \beta, j)$ zur Zustandsmenge Z(j) hinzugefügt.
 - Überprüfung: Für jeden Zustand in der Zustandsmenge Z(j), der die Form (A ::= α αγ, i) hat wird der Zustand (A ::= α α γ, i) zur Zustandsmenge Z(j + 1) hinzugefügt.
 - Vervollständigung: Für jeden Zustand in der Zustandsmenge Z(j), der die Form
 (B ::= β•, i) hat werden alle Zustände in Z(i) gesucht, welche die Form (A ::= α• Bγ, i)
 haben und es wird der Zustand (A ::= αB• γ, i) zur Zustandsmenge Z(j) hinzugefügt.

bis:

- der Zustand $(A := \beta \bullet, 0)$ in der Zustandsmenge Z(n) auftaucht, wobei A das Startsymbol S ist $\Rightarrow w \in L(G_{Parse})$.
- keine Zustände mehr hinzugefügt werden können $\Rightarrow w \notin L(G_{Parse})$.

^aJay Earley, "An efficient context-free parsing".

^bErklärweise wurde von der Webseite Earley parser übernommen.

^cEarley Parser.

 $^{d}L(G_{Parse})$ ist die Sprache, welche durch die Konkrete Grammatik G_{Parse} beschrieben wird.

eAlso eine Folge von Terminalsymbolen und Nicht-Terminalsymbolen.

Definition 1.12: Liveness Analyse

Findet heraus, welche Variablen in welchen Regionen eines Programmes verwendet werden. a

^aG. Siek, Essentials of Compilation.

Definition 1.13: Live Variable

Z

Eine Variable, deren momentaner Wert später im Programmablauf noch verwendet wird. Man sagt auch die Variable ist live. ab

^aEs gibt leider kein allgemein gebräuchliches deutsches Wort für Live Variable.

^bG. Siek, Essentials of Compilation.

Definition 1.14: Graph Coloring

7

Problem, bei dem den Knoten eines Graphen^a Zahlen^b zugewiesen werden sollen, sodass keine zwei adjazente Knoten die gleiche Zahl haben und möglichst wenige unterschiedliche Zahlen gebraucht werden.^{cd}

^aIn Bezug zu Compilerbau ein Ungerichteter Graph.

 b Bzw. Farben.

^cEs gibt leider kein allgemein verwendetes deutsches Wort für Graph Coloring.

^dG. Siek, Essentials of Compilation.

Definition 1.15: Interference Graph

7

Ein ungerichteter Graph mit Variablen als Knoten, der eine Kante zwischen zwei Variablen hat, wenn es sich bei beiden Variablen zu dem Zeitpunkt um Live Variablen (Definition 1.13) handelt. In Bezug auf Graph Coloring (Definition 1.14) bedeutet eine Kante, dass diese zwei Variablen nicht die gleiche Zahl^a zugewiesen bekommen dürfen, weil sie zum selben Zeitpunkt live sind und daher nicht der gleichen Location zugewiesen werden dürfen.^b

^aBzw. Farbe.

^bG. Siek, Essentials of Compilation.

Definition 1.16: Kontrollflussgraph

Z

Gerichteter Graph, der den Kontrollfluss (Definition 1.16) eines Programmes beschreibt.^a

^aG. Siek, Essentials of Compilation.

Definition 1.17: Kontrollfluss

Die Reihenfolge in der z.B. Anweisungen, Funktionsaufrufe usw. eines Programmes ausgewertet werden^a.

^aMan geht hier von einem Programm in einer Imperativen Programmiersprache aus.

Definition 1.18: Kontrollflussanalyse

7

Analyse des Kontrollflusses (Defintion 1.17) eines Programmes, um herauszufinden zwischen welchen Teilen des Programms Daten ausgetauscht werden und welche Abhängigkeiten sich daraus ergeben.

Der simpelste Ansatz ist es, in einen Kontrollflussgraph iterativ einen Algorithmus^a anzuwenden, bis sich an den Werten der Knoten nichts mehr ändert^b.

^aIm Bezug zu Compilerbau die Liveness Analyse.

Definition 1.19: Two-Space Copying Collector

Z

Ein Garbabe Collector, bei dem der Heap in FromSpace und ToSpace unterteilt wird. Bei nicht ausreichendem Speicherplatz auf dem Heap, werden alle Variablen, die in Zukunft noch verwendet werden vom FromSpace zum ToSpace kopiert. Der aktuelle ToSpace wird danach zum neuen FromSpace und der aktuelle FromSpace wird danach zum neuen ToSpace.^a

^aG. Siek, Essentials of Compilation.

Bootstrapping

Wenn eines Tages eine RETI-CPU auf einem FPGA implementiert werden sollte, sodass ein provisorisches Betriebssystem darauf laufen könnte, dann wäre der nächste Schritt einen Self-Compiling Compiler $C_{PicoC_RETI}^{PicoC}$ (Defintion 1.20) zu schreiben. Durch einen Self-Compiling Compiler kann die Unabhängigkeit von der Programmiersprache L_{Python} , in welcher der PicoC-Compiler $C_{PicoC_RETI}^{Python}$ bisher implementiert ist erreicht werden. Des Weiteren kann die Unabhängigkeit von einer anderen Maschine, die bisher immer für das Cross-Compiling (Definition ??) notwendig war erreicht werden. Mittels Bootrapping wird aus dem PicoC-Compiler ein "richtiger Compiler" für die RETI-CPU gemacht, der auf der RETI-CPU selbst läuft.

Anmerkung Q

Im Folgenden wird ein voll ausgeschriebenes Compilerkürzel als $C_{E_A_k_min}^{I_j}$ geschrieben, wobei:

- $C_{E,A,k,min}^{I,j}$ Eingabesprache.
- $C^{I_{-j}}_{E_A_k_min} =$ **A**usgabesprache.
- $C^{I_{-j}}_{E_A_k_min}$
 Version k der Eingabesprache.
- $C_{E_A.k_min}^{I_j}$ = Implementierungssprache bzw. Maschinensprache mit welcher der Compiler läuft.
- $C^{I.j}_{E_A_k_min}$

 Version j der Implementierungssprache.
- $C_{EAk\ min}^{I_{-j}}$ Minimaler Compiler.

bedeuten.

^bBis diese sich **stabilisiert** haben

 $[^]c\mathrm{G}.$ Siek, Essentials of Compilation.

¹Ein üblicher Compiler, wie ihn ein Programmierer verwendet, wie der GCC oder Clang läuft üblicherweise selbst auf der Maschine für welche er kompiliert.

Definition 1.20: Self-compiling Compiler

/

Compiler $C_{E_M}^E$, der in der Eingabesprache L_E implementiert ist, die er kompiliert. Also ein Compiler, der sich selbst kompilieren könnte.^a

^aJ. Earley und Sturgis, "A formalism for translator interactions".

Will man für eine Maschine M_{RETI} , auf der bisher keine anderen Programmiersprachen mittels Bootstrapping (Definition 1.21) zum laufen gebracht wurden, den gerade beschriebenen Self-compiling Compiler $C_{PicoC_RETI}^{PicoC}$ implementieren und hat bereits den gesamtem Self-compiling Compiler $C_{PicoC_RETI}^{PicoC}$ in der Sprache L_{PicoC} implementiert, so stösst man auf ein Problem, dass auf das Henne-Ei-Problem² reduziert werden kann. Man bräuchte, um den Self-compiling Compiler $C_{PicoC_RETI}^{PicoC}$ auf der Maschine M_{PicoC} zu kompilieren bereits einen kompilierten Self-compiling Compiler $C_{PicoC_RETI}^{RETI}$. Es liegt eine zirkulare Abhängigkeit vor, die man nur auflösen kann, indem eine externe Entität zur Hilfe nimmt.

Eine Möglichkeit diese zirkulare Abhängigkeit zu brechen, wäre, dass man den Cross-Compiler $C_{PicoC_RETI}^{Python}$, den man bereits in der Programmiersprache L_{Python} implementiert hat auf einer anderen Maschine M_{other} dazu nutzt, um den Self-compiling Compiler $C_{PicoC_RETI}^{PicoC}$ für die Maschine M_{RETI} zu kompilieren bzw. zu bootstrappen. Der Cross-Compiler $C_{PicoC_RETI}^{Python}$ stellt in diesem Fall einen Bootstrap Compiler (Definition 1.22) dar. Den kompilierten Compiler $C_{PicoC_RETI}^{RETI}$ kann man dann einfach von der Maschine M_{other} auf die Maschine M_{RETI} kopieren³. In Abbildung 1.2 ist das ganze in einem T-Diagramm (siehe Unterkapitel ??) dargestellt.

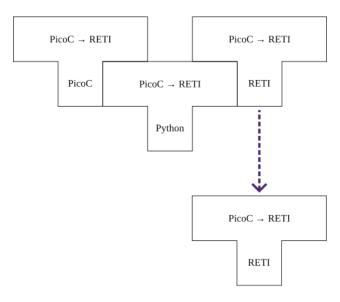


Abbildung 1.2: Cross-Compiler als Bootstrap Compiler.

Definition 1.21: Bootstrapping

7

Wenn man einen Self-compiling Compiler $C_{E_M}^E$ einer Eingabesprache L_E auf einer Maschine mit der Maschinensprache L_M zum laufen bringt^{abcd}. Dabei ist die Art von Bootstrapping in 1.21.1

²Beschreibt die Situation, wenn ein System sich selbst als Abhängigkeit hat, damit es überhaupt einen Anfang für dieses System geben kann. Dafür steht das Problem mit der Henne und dem Ei sinnbildlich, da hier die Frage ist, wie das ganze seinen Anfang genommen hat, da beides zirkular voneinander abhängt.

³Im Fall, dass auf der Maschine M_{RETI} die Programmiersprache L_{Python} bereits mittels Bootstrapping zum Laufen gebracht wurde, könnte der Self-compiling Compiler $C_{PicoC_RETI}^{PicoC}$ auch mithife des Cross-Compilers $C_{PicoC_RETI}^{Python}$ als externe Entität auf der Maschine M_{RETI} selbst kompiliert werden.

nochmal gesondert hervorzuheben.

1.21.1: Wenn man die aktuelle Version eines Self-compiling Compilers $C_{E_M_i}^{E_i}$ der Eingabesprache L_{E_i} mithilfe von früheren Versionen seiner selbst für eine Maschine mit der Maschinensprache L_M kompiliert. Man schreibt also z.B. die aktuelle Version des Self-compiling Compilers $C_{E_M_i}^{E_i-1}$ in der Sprache L_{E_i-1} , welche von der früheren Version des Self-compiling Compilers $C_{E_M_i-1}^{E_i-1}$, genuer dem kompilierten Self-compiling Compiler $C_{E_M_i-1}^M$, kompiliert wird.

Man erhält so einen kompilierten Self-compiling Compiler C_{E-M-i}^{M} , der dazu in der Lage wäre den Self-compiling Compiler C_{E-M-i}^{E-i} zu kompilieren, der in selben Version der Eingabesprache L_E implementiert ist, die er kompiliert. Man schafft es so iterativ immer umfangreichere Compiler zu erstellen. efg

^aZ.B. mithilfe eines Bootstrap Compilers.

^bDer Begriff hat seinen Ursprung in der englischen Redewendung "pulling yourself up by your own bootstraps", was im deutschen ungefähr der aus den Lügengeschichten des Freiherrn von Münchhausen bekannten Redewendung "sich am eigenen Schopf aus dem Sumpf ziehen"entspricht.

 c Hat man einmal einen solchen Self-compiling Compiler $C_{E_{-M}}^{E}$ auf der Maschine mit der Maschinensprache L_{M} zum laufen gebracht, so kann man den Compiler auf dieser Maschine weiterentwickeln, ohne von externen Entitäten, wie einer bestimmten Programmiersprache L_{O} , in welcher der Compiler oder eine frühere Version des Compilers ursprünglich implementiert war abhängig zu sein.

^dEinen Compiler in der Sprache zu implementieren, die er selbst kompiliert und diesen Compiler dann sich selbst kompilieren zu lassen, kann eine gute Probe aufs Exempel darstellen, um zu prüfen, ob der Compiler auch wirklich funktioniert.

^eEs ist hierbei theoretisch nicht notwendig den letzten Self-compiling Compiler $C_{E.M.i-1}^{E.i-1}$ für das Kompilieren des neuen Self-compiling Compilers $C_{E.M.i}^{E.i}$ zu verwenden, wenn z.B. der Self-compiling Compiler $C_{E.M.i-3}^{E.i-3}$ auch bereits alle Funktionalitäten, die beim Implementieren des Self-compiling Compilers $C_{E.M.i}^{E.i}$ verwendet wurden kompilieren kann.

^fDer Begriff ist sinnverwandt mit dem Booten eines Computers, wo die wichtigste Software, der Kernel zuerst in den Hauptspeicher geladen wird und darauf aufbauend von diesem dann das Betriebssystem, welches bei Bedarf dann Systemsoftware (Software, die das Ausführen von Anwendungssoftware ermöglicht oder unterstützt, wie z.B. Treiber) und Anwendungssoftware (Software, deren Anwendung darin besteht, dass sie dem Benutzer unmittelbar eine Dienstleistung zur Verfügung stellt) lädt.

^gJ. Earley und Sturgis, "A formalism for translator interactions".

Definition 1.22: Boostrap Compiler

Compiler $C_{E_M}^O$, der es ermöglicht einen Self-compiling Compiler $C_{E_M}^E$ zu boostrapen (Definition 1.21). Hierzu wird der Self-compiling Compiler $C_{E_M}^E$ mit dem Bootstrap Compiler $C_{E_M}^O$ kompiliert^a. Der Bootstrap Compiler $C_{E_M}^O$ stellt eine externe Entität dar, die es ermöglicht die zirkulare Abhängikeit zu brechen, dass initial ein kompilierter Self-compiling Compiler $C_{E_M}^M$ bereits vorliegen müsste, damit der Self-compiling Compiler $C_{E_M}^E$ sich selbst kompilieren könnte. b

 a Dabei kann es sich um einen lokal auf der Maschine selbst laufenden Compiler oder auch um einen Cross-Compiler handeln.

 b Thiemann, "Compilerbau".

Aufbauend auf dem Self-compiling Compiler $C_{PicoC_RETI}^{PicoC}$, der einen Minimalen Compiler (Definition 1.23) für eine Teilmenge der Programmiersprache L_C darstellt, könnte man auch noch weitere Funktionalitäten der Programmiersprache L_C mittels Bootstrapping implementieren⁴.

Das bewerkstelligt man, indem man iterativ auf der Zielmaschine M_{RETI} selbst, aufbauend auf diesem Minimalen Compiler $C_{PicoC_RETI}^{PicoC}$, wie in Subdefinition 1.21.1 den Minimalen Compiler schrittweise zu einem immer umfangreicheren Compiler weiterentwickelt. In Abbildung 1.3 ist das ganze in einem T-Diagramm (siehe Unterkapitel ??) dargestellt.

⁴Natürlich könnte man aber auch einfach den Cross-Compiler $C_{PicoC_RETI}^{Python}$ um weitere Funktionalitäten von L_C erweitern, hat dann aber weiterhin eine Abhängigkeit von der Programmiersprache L_{Python} .

Anmerkung Q

Einen ersten Minimalen Compiler $C_{E_M_min}^O$ der Sprache L_E für eine Maschine mit der Maschinensprache L_M kann man entweder mittels eines externen Bootstrap Compilers $C_{O_M}^M$ kompilieren zu $C_{E_M_min}^M$ oder man implementiert ihn direkt in der Maschinensprache L_M oder wenn ein Assembler $\mathbb{A}_{A_M}^M$ vorhanden ist, in der Assemblersprache L_A .

Dies ist nur beim allerersten Minimalen Compiler $C_{E_M_1_min}^O$ für eine allererste abstrakte Programmiersprache L_{E_1} mit z.B. Schleifen, Verzweigungen usw. notwendig. Ansonsten kann man immer eine Kette, die beim allerersten Minimalen Compiler $C_{E_M_1_min}^O$ anfängt fortführen, in der immer ein Compiler einen anderen Compiler kompiliert bzw. einen ersten Minimalen Compiler kompiliert und dieser Minimale Compiler dann eine umfangreichere Version von sich kompiliert usw.

Definition 1.23: Minimaler Compiler

Z

Compiler $C_{E_M_min}^O$, der nur die notwendigsten Funktionalitäten einer Wunschsprache L_E , wie Schleifen, Verzweigungen kompiliert, die für die Implementierung eines Self-compiling Compilers $C_{E_M}^E$ oder einer bestimmten Version $C_{E_M_i}^{E_i}$ dieses Compilers wichtig sind. ab

Anmerkung Q

Auch wenn ein Self-compiling Compiler $C_{E_M_i}^{E_i}$ in der Subdefinition 1.21.1 selbst in einer früheren Version L_{E_i-1} der Programmiersprache L_{E_i} geschrieben wird, wird dieser nicht mit $C_{E_M_i}^{E_i-1}$ bezeichnet, sondern mit $C_{E_M_i}^{E_i}$. Es geht bei Self-compiling Compilern darum, dass diese zwar in der Subdefinition 1.21.1 eine frühere Version $C_{E_{i-1}}^{E_{i-1}}$ nutzen, um sich selbst kompilieren, aber auch in der Lage sind sich selber zu kompilieren.

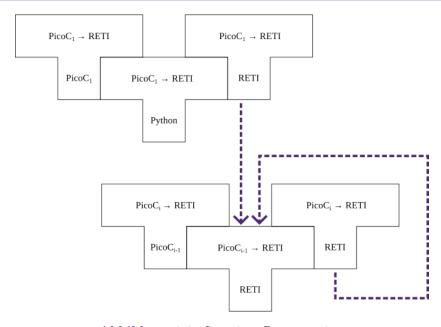


Abbildung 1.3: Iteratives Bootstrapping.

 $^{{}^}a$ Den PicoC-Compiler $C^{Python}_{PicoC_RETI}$ könnte man auch als einen Minimalen Compiler ansehen.

^bThiemann, "Compilerbau".

Literatur

Online

- Earley Parser. URL: https://rahul.gopinath.org/post/2021/02/06/earley-parsing/ (besucht am 20.06.2022).
- Parsers Lark documentation. URL: https://lark-parser.readthedocs.io/en/latest/parsers. html (besucht am 20.06.2022).

Bücher

• G. Siek, Jeremy. *Essentials of Compilation*. 28. Jan. 2022. URL: https://iucompilercourse.github.io/IU-Fall-2021/ (besucht am 28.01.2022).

Artikel

- Earley, J. und Howard E. Sturgis. "A formalism for translator interactions". In: *CACM* (1970). DOI: 10.1145/355598.362740.
- Earley, Jay. "An efficient context-free parsing". In: 13 (1968). URL: https://web.archive.org/web/20040708052627/http://www-2.cs.cmu.edu/afs/cs.cmu.edu/project/cmt-55/lti/Courses/711/Class-notes/p94-earley.pdf (besucht am 10.08.2022).

Vorlesungen

- Nebel, Bernhard. "Theoretische Informatik". Vorlesung. Vorlesung. Universität Freiburg, 2020. URL: http://gki.informatik.uni-freiburg.de/teaching/ss20/info3/index_de.html (besucht am 09.07.2022).
- Scholl, Christoph. "Betriebssysteme". Vorlesung. Vorlesung. Universität Freiburg, 2020. URL: https://abs.informatik.uni-freiburg.de/src/teach_main.php?id=157 (besucht am 09.07.2022).
- Scholl, Philipp. "Einführung in Embedded Systems". Vorlesung. Vorlesung. Universität Freiburg, 2021. URL: https://earth.informatik.uni-freiburg.de/uploads/es-2122/ (besucht am 09.07.2022).
- Thiemann, Peter. "Compilerbau". Vorlesung. Vorlesung. Universität Freiburg, 2021. URL: http://proglang.informatik.uni-freiburg.de/teaching/compilerbau/2021ws/ (besucht am 09.07.2022).
- — "Einführung in die Programmierung". Vorlesung. Vorlesung. Universität Freiburg, 2018. URL: http://proglang.informatik.uni-freiburg.de/teaching/info1/2018/ (besucht am 09.07.2022).

Sonstige Quellen

• Earley parser. In: Wikipedia. Page Version ID: 1090848932. 31. Mai 2022. URL: https://en.wikipedia.org/w/index.php?title=Earley_parser&oldid=1090848932 (besucht am 15.08.2022).